メールネットワークの時間窓分析

高木悠歩

2026 年 10 月 31 日

目次

1 **はじめに** 2

2 **研究の目的** 2

3 **理論** 3
- 3.1 グラフの基本 . . . 3
- 3.2 Modularity . . . 3
- 3.3 Louvain 法 . . . 4
- 3.4 分割の比較：Jaccard 係数と NMI . . . 6

4 **データ** 9
- 4.1 データセット . . . 9
- 4.2 時間窓 . . . 9
- 4.3 主分析と補足分析に使う時間窓 . . . 10

5 **方法** 10
- 5.1 グラフの構築 . . . 10
- 5.2 コミュニティ検出 . . . 11
- 5.3 隣接する窓の比較 . . . 11
- 5.4 変化の分類 . . . 11
- 5.5 安定性の検証 . . . 11
- 5.6 特徴の比較 . . . 12

6 **結果** 12
- 6.1 窓 0〜4 の概要と隣接窓の NMI . . . 12
- 6.2 変化の分類 . . . 12
- 6.3 安定性 . . . 12
- 6.4 変化とコミュニティの特徴 . . . 13
- 6.5 補足分析 . . . 15

7 考察 15

8 限界 15

9 今後の展望 16

10 おわりに 16

11 再現方法 16

1 はじめに

人と人とのつながりをネットワークとして表すと，その中には，互いに密につながった人の集まり（コミュニティ）が現れることが多い．組織の中のメールのやり取りであれば，コミュニティは部署やプロジェクトのような，日常的に連絡を取り合うまとまりに対応すると考えられる．こうしたまとまりは固定されたものではなく，時間とともに続いたり，分かれたり，まとまったりしていくはずである．

本研究は当初，ノードの中心性（重要度）を軸にネットワークを分析していた．しかし，中心性の定義を変えて比べても，はっきりした違いが見られなかった．そこでテーマとデータを見直し，コミュニティ構造とその時間変化に焦点を当てることにした．2026 年 9 月の中間発表では，メールネットワークを 100 日ごとの時間窓に分けてコミュニティを検出し，多くのコミュニティが次の期間にも維持される一方で，一部に分裂の兆候が見られることを報告した．

本レポートでは，中間発表後に行った分析をまとめる．特に，中間発表で見られた分裂の兆候が実際の変化なのか，コミュニティ検出アルゴリズムの揺らぎによるものなのかを検証する．

2 研究の目的

本研究では，ある研究機関のメールの送受信記録をネットワークとして表現し，ネットワーク内のコミュニティ構造が時間とともにどのように変化するかを調べる．中心となる問いは次の 3 つである．

1. コミュニティ構造は時間とともにどう変化するか．コミュニティが維持・分裂・統合・消滅・出現する頻度を整理する．
2. 検出された変化はどの程度安定しているか．実際の期間の間の差と，コミュニティ検出アルゴリズムの実行条件による揺らぎを区別する．
3. 変化とコミュニティの特徴にはどのような関連があるか．規模，内部密度，外部との接続などを比較する．

中間発表では，一部のコミュニティに「分裂の兆候」が見られることを報告し，それが本物の変化か，アルゴリズムの揺らぎによるものかを確かめることを今後の課題とした．本レポートでは，この問いに特に重点を置く．

なお，本研究で扱うコミュニティの分裂・統合は，あくまでネットワーク上の検出結果の変化である．それだけで，実際の組織改編や人間関係の変化を示したことにはならない．

3 理論

3.1 グラフの基本

本研究で用いるグラフの用語を，本研究での使い方とともに整理する．

3.1.1 有向グラフと無向グラフ

グラフ $G = (V, E)$ は，ノードの集合 V と，ノードの組を結ぶ辺の集合 E からなる．辺に向きがあるものを有向グラフ，向きがないものを無向グラフと呼ぶ．メールは送信者から受信者への向きを持つが，本研究の主分析では向きを区別しない無向グラフを用いる．このとき，A → B と B → A のメールは同じ 1 本の辺として扱われる．

3.1.2 重み

辺に数値を付けたものを重み付きグラフと呼ぶ．本研究の主分析では重みを付けず，同じ組の間に複数のメールがあっても 1 本の辺とする．補足分析では，組ごとのメール数を辺の重みとする．

3.1.3 次数と密度

ノード i の次数 k_i は，そのノードにつながる辺の数である．無向グラフでは，すべてのノードの次数の和は辺の数 m の 2 倍（$\sum_i k_i = 2m$）になる．n 個のノードからなるグラフの密度は，実際の辺の数を張り得る辺の数で割った値

$$\rho = \frac{m}{n(n-1)/2} \tag{1}$$

であり，0 から 1 の値をとる．張り得る辺の数はノード数のおよそ 2 乗で増えるため，ノードの多いグラフほど密度は小さくなりやすい．本研究では，コミュニティ内部の部分グラフについて密度を計算する．

3.1.4 連結成分

辺をたどって互いに行き来できるノードの集まりを連結成分と呼ぶ．有向グラフでは，向きを無視して行き来できる集まりを弱連結成分，向きどおりに行き来できる集まりを強連結成分と呼ぶ．本研究では，各時間窓の無向グラフが連結成分にいくつ分かれているかを，ネットワークが断片化している程度の目安として用いる．

3.2 Modularity

3.2.1 目的

本研究では，メールの送受信記録から人々のつながりをネットワークとして表現する．ノードは人，辺はメールの送受信関係を表し，ネットワーク内で相対的につながりが密なノードの集まりをコミュニティと呼ぶ．

Modularity [1, 2] は，ネットワークをコミュニティに分割したとき，観測されたつながり方がその分割をどの程度支持しているかを評価する指標の一つである．基本的な考え方は，「同じコミュニティの内部に実際に存在する辺の本数が，次数を考慮した基準のもとで期待される辺の本数と比べてどれだけ多いか」を評価する

ことにある．

3.2.2 定義

無向・重みなしグラフの Modularity Q は次式で定義される．

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j) \tag{2}$$

ここで，

- m：グラフ全体の辺数
- A_{ij}：ノード i，j の間に辺があれば 1，なければ 0
- k_i：ノード i の次数
- c_i：ノード i が所属するコミュニティ
- $\delta(c_i, c_j)$：$c_i = c_j$（ノード i，j が同じコミュニティ）なら 1，異なれば 0

である．すなわち，同じコミュニティに属するノードの組について「実際の辺の数」と「期待される辺の数」の差を合計し，全体の辺数で正規化した値が Q である．

3.2.3 帰無モデル

特定のグループ内に辺が集中しているかを調べる際，実際の辺の数だけを見ると，単に接続数の多い人が集まっているだけという可能性が残る．そこで Modularity では，各ノードの次数を保ったまま辺をランダムにつなぎ直したネットワーク（帰無モデル）を考え，そのもとで期待される辺の数を基準にする．

ノード a，b の間に帰無モデルのもとで期待される辺の数は

$$E_{ab} = \frac{k_a k_b}{2m} \tag{3}$$

で与えられる．次数を「そのノードが持つ辺の端の数」ととらえると，無向グラフでは 1 本の辺につき端が 2 つあるため，グラフ全体の端の数は $2m$ となる．ノード a の端 k_a 個のそれぞれが，全体の端のうちノード b の端（$k_b/2m$ の割合）とつながると考えると，近似的な期待値は次数の積を全体の端の数で割った形になる．

3.2.4 解釈と限界

Q が正で大きいほど，その分割では帰無モデルに比べてコミュニティ内部に辺が集まっていることを示す．0 付近では帰無モデルと比べて内部への辺の明確な集中が見られず，負の値ではコミュニティ内部の辺が帰無モデルの期待値より少ない傾向があることを示す．

ただし，すべてのネットワークに共通する絶対的な基準値はない．そのため，異なるネットワークや異なる分析条件のもとで得られた値を比較することには限界がある．

3.3 Louvain 法

3.3.1 概要

Louvain 法 [3] は，Modularity を大きくするようなコミュニティ分割を効率的に探索するアルゴリズムであり，大規模なネットワークでも比較的効率よく実行できる．入力はネットワーク（ノード，辺，必要に応じて辺の重み），出力は各ノードのコミュニティ所属である．Louvain 法は次の 2 つの段階を繰り返す．

第 1 段階 ノードの移動：Modularity が改善するように，各ノードの所属コミュニティを変更する．
第 2 段階 ネットワークの集約：検出された各コミュニティを 1 つのノードにまとめ，より小さなネットワークを作る．

3.3.2 第 1 段階：ノードの移動

はじめに，各ノードがそれぞれ独立したコミュニティに属する状態（コミュニティ数 = ノード数）から始める．

次に，ノードを 1 つずつ順に取り上げ，そのノードを隣接ノードが属するコミュニティへ移動させた場合の Modularity の変化量

$$\Delta Q = Q_{\text{after}} - Q_{\text{before}} \tag{4}$$

を計算する．この ΔQ を Modularity gain（モジュラリティの増加量）と呼ぶ．移動先の候補の中で ΔQ が最大となるコミュニティへ移動させ，正の ΔQ が得られない場合は移動させない．これを，どのノードを移動させても Modularity が改善しなくなるまで繰り返す．

3.3.3 第 2 段階：ネットワークの集約

第 1 段階でノードの移動が落ち着いたら，各コミュニティを 1 つのノードとして扱う．元のコミュニティ内部にあった辺は集約ノードの自己ループとして，コミュニティ間の辺は集約ノード同士をつなぐ辺として表現される．

集約したネットワークに対して再び第 1 段階を行い，改善が十分に小さくなるまでこれを繰り返す．第 1 段階だけではノード単位の局所的な改善にとどまるが，集約を挟むことで，ノード単位の移動だけでは見つかりにくい，より大きな構造を探索できる．

なお，Louvain 法はヒューリスティックな手法であり，Modularity が最大となる分割を見つけることは保証されない．したがって，得られた分割は唯一の正解とは限らない．

3.3.4 乱数シード

第 1 段階でノードを取り上げる順序が変わると，途中のコミュニティ構造も変わるため，最終的に異なる分割に到達することがある．実装では，この順序を乱数で決めている [4]．乱数シードを固定すると，同じ入力・同じ実行条件のもとで結果を再現できる．ただし，シードの固定は再現性を確保するためのものであり，検出結果が安定していることを示すものではない．

3.3.5 resolution（解像度パラメータ）

resolution γ は，Modularity を最適化する際のコミュニティの大きさの傾向を調整するパラメータであり，式 (2) を次のように変更する．

$$Q_\gamma = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \gamma \frac{k_i k_j}{2m} \right) \delta(c_i, c_j) \tag{5}$$

- $\gamma < 1$：帰無モデルの期待辺数によるペナルティが相対的に小さくなり，より大きなコミュニティが優先される傾向がある．
- $\gamma = 1$：標準的な設定であり，式 (2) と一致する．

- $\gamma > 1$：帰無モデルの期待辺数によるペナルティが相対的に大きくなり，より小さなコミュニティが優先される傾向がある．

組織全体の大きなまとまりを知りたい場合と，部署内の細かなグループまで知りたい場合とでは，適したコミュニティの大きさが異なり得る．ただし，γ を大きくすればコミュニティ数が一定の割合で増えるといった単純な関係はなく，その影響はネットワークの構造によって異なる．

また，γ が異なれば最適化される目的関数自体が異なるため，同じグラフと分割に対しても Modularity の値は変化し得る．したがって，異なる γ で得られた Modularity の値を単純に比較して，コミュニティ構造の明瞭さや分割の優劣を判断することは適切ではない．

3.4 分割の比較：Jaccard 係数と NMI

異なる時間窓で得られたコミュニティについて，人数を比較するだけでは，どの程度メンバーが維持されたかはわからない．また，個別のコミュニティを比較するだけでは，ネットワーク全体のコミュニティ構造がどの程度変わったかを十分に評価できない．

そこで，個々のコミュニティ同士を比較してコミュニティの継続や分裂・統合を追跡するために Jaccard 係数を，ネットワーク全体のコミュニティ分割を比較して分割全体の類似度を評価するために NMI を用いる．

3.4.1 Jaccard 係数

2 つの集合 A，B の Jaccard 係数 [5] は次式で定義される．

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} \tag{6}$$

ここで，$|A|$ は集合 A の要素数である．値の範囲は $0 \leq J(A,B) \leq 1$ であり，1 のとき 2 つの集合は完全に一致し，0 のとき共通する要素がない．

Jaccard 係数はメンバーの重なりを直接評価するため，メンバーの入れ替わりを調べるのに適している．一方で，比較できるのは 2 つの集合の組であるため，コミュニティが多数ある場合は，どのコミュニティ同士を対応させるかを別に定める必要がある．

3.4.2 相互情報量

相互情報量（MI: Mutual Information）は，あるノードが一方の分割でどのコミュニティに属しているかがわかると，もう一方の分割での所属先についてどれだけ情報が得られるかを表す．2 つの分割の所属関係がよく対応しているほど相互情報量は大きく，対応していないほど小さい．

比較する N 個のノードについて，一方の分割での所属コミュニティを確率変数 X，もう一方の分割での所属コミュニティを確率変数 Y とする．コミュニティ x に属するノード数を n_x，x と y の両方に属するノード数を n_{xy} とすると，各確率はノード数の割合として

$$p(x) = \frac{n_x}{N}, \quad p(y) = \frac{n_y}{N}, \quad p(x,y) = \frac{n_{xy}}{N} \tag{7}$$

で与えられる．このとき，相互情報量は次式で定義される [6].

$$I(X;Y) = \sum_x \sum_y p(x,y) \log \frac{p(x,y)}{p(x)\,p(y)} \tag{8}$$

ここで $p(x)\,p(y)$ は，X と Y が独立であると仮定した場合の同時確率である．比 $p(x,y)/p(x)\,p(y)$ が 1 より大きいとき，その組み合わせは独立の場合より起こりやすく，1 のとき独立の場合と同じ，1 より小さいとき独立の場合より起こりにくい．この比の対数を同時確率 $p(x,y)$ で重み付けして合計したものが相互情報量であり，X と Y の間の統計的な依存関係の強さを表す．

相互情報量はエントロピーを用いて

$$I(X;Y) = H(X) + H(Y) - H(X,Y) = H(X) - H(X \mid Y) \tag{9}$$

とも表せる．ここで，

$$H(X) = -\sum_{x} p(x) \log p(x), \quad H(X,Y) = -\sum_{x}\sum_{y} p(x,y) \log p(x,y) \tag{10}$$

はそれぞれエントロピーと同時エントロピーであり，$H(X \mid Y)$ は条件付きエントロピーである．$H(X)$ は Y の情報を知らないときの X の不確実性，$H(X \mid Y)$ は Y の情報を知った後に残る X の不確実性を表す．したがって，$I(X;Y)$ は Y の情報を得ることで減少した X の不確実性と解釈できる．

3.4.3 NMI（正規化相互情報量）

相互情報量そのものは，分割の細かさ（コミュニティの数や大きさ）の影響を受けやすい．そのため，比較しやすいように正規化した NMI（Normalized Mutual Information）が用いられる．正規化の方法は複数あり [7, 8]，よく使われる定義の一つが次式である [8]．

$$\mathrm{NMI}(X,Y) = \frac{2\,I(X;Y)}{H(X) + H(Y)} \tag{11}$$

これは相互情報量を 2 つのエントロピーの算術平均で割ったものである．NMI は 0 から 1 の値をとり，2 つの分割が（コミュニティの番号の付け方を除いて）完全に一致するとき 1，所属関係が独立であるとき 0 となる．NMI が高いほど，ノードのコミュニティ所属関係が全体としてよく対応していることを示す．

本研究で用いる scikit-learn の関数 `normalized_mutual_info_score` [13] は，既定の設定（`average_method="arithmetic"`）で式 (11) を計算する．対数には自然対数が使われるが，NMI は比であるため，対数の底によって値は変わらない．なお，この NMI は偶然による一致を補正していない [8]．これを補正した指標が AMI である（3.4.4 節）．

3.4.4 AMI（調整相互情報量）

考え方

NMI は，分割を非常に細かくした場合など，実際には意味のある対応関係がなくても，ある程度の値をとることがある．また，コミュニティの数や各コミュニティの規模によって，NMI の値が影響を受けることもある．そこで，2 つの分割が互いに独立であっても偶然に生じると期待される相互情報量を差し引いて補正した指標が，AMI（Adjusted Mutual Information） [8] である．偶然による一致を差し引いて分割の類似度を評価する考え方は，Adjusted Rand Index [9] などの調整指標と共通している．

定義

2 つの分割 U，V の AMI は次式で定義される．

$$\mathrm{AMI}(U,V) = \frac{I(U;V) - \mathbb{E}[I(U;V)]}{\frac{1}{2}\{H(U) + H(V)\} - \mathbb{E}[I(U;V)]} \tag{12}$$

ここで，$I(U;V)$ は 2 つの分割の間の相互情報量，$H(U)$ は分割 U のエントロピー，$\mathbb{E}[I(U;V)]$ は偶然に生じると期待される相互情報量（期待相互情報量）である．分子は実際の相互情報量から偶然に期待される分を差し引いたもの，分母は NMI と同じ正規化の値から偶然に期待される分を差し引いたものである．AMI は，2 つの分割が（番号の付け方を除いて）完全に一致するとき 1，偶然と同程度の一致しかないとき 0 付近の値をとり，偶然を下回る場合は負の値もとり得る．

本研究で用いる scikit-learn の `adjusted_mutual_info_score` [12] は，既定の設定で，分母の正規化に NMI と同じ算術平均を用いる．

期待相互情報量と置換モデル

$\mathbb{E}[I(U;V)]$ は，2 つの分割が依存関係によらず偶然に作られた場合に，どの程度の相互情報量が期待されるかを表す．この期待値を求めるにあたり，次の条件を置く．

- 比較するノードの数 N は固定する．
- それぞれの分割の各コミュニティの人数も固定する．
- この条件のもとで，ノードの割り当てがランダムである場合を考える．

これを置換モデル（permutation model）と呼ぶ．

分割 U のコミュニティ i の人数を $a_i = |U_i|$，分割 V のコミュニティ j の人数を $b_j = |V_j|$，両方に共通するノード数を $n_{ij} = |U_i \cap V_j|$ とする．置換モデルのもとでの期待相互情報量は

$$\mathbb{E}[I(U;V)] = \sum_i \sum_j \sum_k \frac{k}{N} \log\left(\frac{Nk}{a_i b_j}\right) P(n_{ij} = k) \tag{13}$$

で与えられる [8]．ここで $P(n_{ij} = k)$ は，置換モデルのもとで共通ノード数がちょうど k になる確率であり，次に述べる超幾何分布に従う．$k = 0$ の項は 0 として扱う．

超幾何分布

超幾何分布 [10] は，全体の個数と，そのうち特定の性質を持つものの個数が決まっている母集団から，重複なしで取り出す場合に使う分布である．取り出したものを毎回戻す場合は二項分布になるのに対し，超幾何分布は戻さない場合を扱う [11]．

母集団全体の要素数を N，そのうち特定の性質を持つ要素数を K，取り出す要素数を n とし，取り出した n 個の中に含まれる特定の性質を持つ要素の数を確率変数 X とすると，$X \sim \mathrm{Hypergeometric}(N, K, n)$ と書く．X がちょうど k になる確率（確率質量関数）は

$$P(X = k) = \frac{\binom{K}{k}\binom{N-K}{n-k}}{\binom{N}{n}} \tag{14}$$

である．分母は母集団全体から n 個を選ぶ方法の数，分子は特定の性質を持つ K 個から k 個を選び，それ以外の $N - K$ 個から残りの $n - k$ 個を選ぶ方法の数である．取り出せる個数は母集団の実際の個数に制約されるため，X がとり得る値の範囲は $\max(0, n + K - N) \le k \le \min(K, n)$ である．

期待相互情報量への適用

AMI では，N を全ノード数，K を分割 U のコミュニティ i の人数 a_i，n を分割 V のコミュニティ j の人数 b_j とみなす．すなわち，N 個のノードから V_j に入る b_j 個をランダムに選んだとき，そのうち U_i に属

するものの数が n_{ij} である．したがって，

$$P(n_{ij}=k)=\frac{\binom{a_i}{k}\binom{N-a_i}{b_j-k}}{\binom{N}{b_j}},\quad \max(0,\,a_i+b_j-N)\le k\le \min(a_i,b_j) \tag{15}$$

となり，これを式 (13) に用いて期待相互情報量を計算する．

注意点

AMI は分割全体の類似度を評価する指標である．AMI が低下した場合，分割の構造が変化したことはわかるが，1 つのコミュニティが複数に分裂したのか，複数のコミュニティが統合されたのか，多数のノードが別のコミュニティに移動したのかは区別できない．これらを区別するには，Jaccard 係数などを使って個々のコミュニティの関係を調べる必要がある．

また，AMI の意味は，どのようなランダムな分割を基準にするかによって決まる．一般に用いられるのは各コミュニティの規模を固定した置換モデルであり，あらゆる種類の偶然性を補正するわけではない．

3.4.5 適用上の注意

時間窓ごとのメールネットワークには，ある時間窓にしか現れない人が含まれ得る．そのため，NMI や AMI を計算する際は，両方の時間窓に共通するノードだけに対象を限定するのか，ノード集合の変化も含めた別の評価を行うのかを明確にする必要がある．共通ノードだけで計算すると，新規参加者や離脱者の情報は直接評価されなくなるため，NMI や AMI の解釈はこの選択に大きく依存する．

4 データ

4.1 データセット

公開データセット email-Eu-core-temporal（SNAP）を用いた．ヨーロッパのある研究機関におけるメールの送受信記録であり，各行が「送信者 ID，受信者 ID，時刻（開始からの経過秒数）」の 1 件のメールを表す．メールは 332,334 件，登場する人は 986 人，期間は 0 日目から 803 日目である．送信者と受信者が同じ行（自己ループ）はなかった．

4.2 時間窓

経過秒数を日に直し（$\mathrm{day}=\lfloor t/86400 \rfloor$），100 日ごとに区切って時間窓 0〜8 を作った．ただし，日ごとのメール件数を調べると，526 日目から 796 日目までの 271 日間は記録が 1 件もなかった．このため，窓 6 には記録がなく，窓 5 は最初の 26 日分（500〜525 日目），窓 7 は最後の 3 日分（797〜799 日目），窓 8 は 4 日分（800〜803 日目）しか記録がない（表 1）．

図 1 に，各窓のノード数，辺数，コミュニティ数，Modularity の推移を示す．窓 5 以降は Modularity が高く，コミュニティ数も多い．

表 1　各時間窓の観測期間と規模（無向・重みなしグラフ）

窓	記録のある期間（日）	日数	メール件数	ノード数	辺数	連結成分	扱い
0	0–99	100	52,291	789	6,276	1	主分析
1	100–199	100	62,013	779	6,441	1	主分析
2	200–299	100	60,062	783	6,517	1	主分析
3	300–399	100	68,434	805	6,941	1	主分析
4	400–499	100	65,068	850	7,474	2	主分析
5	500–525	26	22,042	751	3,989	3	補足
6	—	0	0	—	—	—	—
7	797–799	3	686	309	341	27	補足（8 と結合）
8	800–803	4	1,738	503	896	5	補足（7 と結合）

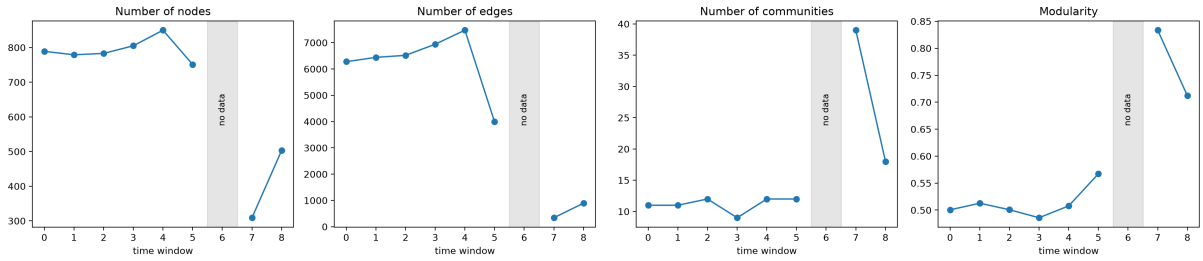


図 1　各時間窓のノード数・辺数・コミュニティ数・Modularity（窓 6 は記録なし）

4.3　主分析と補足分析に使う時間窓

観測日数が短いことの影響を調べるため，100 日分そろっている窓 0〜4 を，それぞれ最初の k 日だけに切り詰めて同じ分析を行った（表 2）．その結果，通常の窓でも観測日数を短くするだけで Modularity が上がり，コミュニティ数と連結成分数が増えた．窓 5，窓 7・8 の値は，同じ日数に切り詰めた窓 0〜4 の範囲にほぼ収まる．すなわち，窓 5 以降で Modularity が高いことは，観測日数の短さで説明できる．

そこで，観測日数がそろっている窓 0〜4 を主分析の対象とした．窓 5（26 日）は補足分析とし，窓 0〜4 を最初の 26 日に切り詰めたものと比較した．窓 7・8 は結合して 1 つの窓（797〜803 日目の 7 日間）とし，窓 0〜4 を最初の 7 日に切り詰めたものと比較した．窓 7・8 を結合することで，連結成分数は 27 から 4 に減った．

5　方法

5.1　グラフの構築

各時間窓について，その期間に送信または受信した人をノード，メールのやり取りがあった人の組を辺とする無向・重みなしグラフを作った．同じ組の間の複数のメールは 1 本の辺とし，送受信の向きは区別しない．補足分析として，組ごとのメール数を重みとする重み付きグラフも作った．

表 2　観測日数をそろえた比較（括弧内は窓 0〜4 の範囲）

対象	ノード数	連結成分	コミュニティ数	Modularity
窓 0〜4（100 日）	779–850	1–2	9–12	0.486–0.513
窓 0〜4 の最初の 26 日	634–696	2–5	11–16	0.564–0.655
窓 5（26 日）	751	3	12	0.567
窓 0〜4 の最初の 7 日	311–599	3–14	14–24	0.655–0.708
窓 7 + 8（7 日）	539	4	15	0.687
窓 0〜4 の最初の 3 日	253–524	7–19	21–32	0.702–0.802
窓 7（3 日）	309	27	39	0.834

5.2　コミュニティ検出

NetworkX [4] の Louvain 法（`louvain_communities`）を用いた．resolution はすべての窓で $\gamma = 1$ に固定した．主結果は乱数シード 42 で得た分割とし，安定性の検証では乱数シードを 0〜19 の 20 通りに変えた．

5.3　隣接する窓の比較

隣り合う窓の分割を，両方の窓に登場する人（共通ノード）だけに限定して比較した．窓全体の分割の類似度は NMI（式 (11)）で測り，偶然による一致を補正した AMI（式 (12)）も併記した．窓 0〜4 では，各窓の人の 9 割以上が次の窓にも登場し，入れ替わる人（各窓の 6〜11%）の多くは次数 1〜2 の人であった．

5.4　変化の分類

隣り合う窓 $a \to b$ について，共通ノードだけを使い，次のように分類した．前の窓のコミュニティ A の共通ノードのうち割合 θ 以上が入った後の窓のコミュニティ B を，A の**行き先**とする．また，後の窓のコミュニティ B の共通ノードのうち割合 θ 以上を占める前の窓のコミュニティ A を，B の**出どころ**とする．

- 分裂：A の行き先が 2 つ以上
- 消滅：A の行き先がない
- 維持：A の行き先が 1 つ（B）で，B の出どころが A だけ
- 統合：A の行き先が 1 つで，維持に当たらない（B に吸収された場合を含む）
- 統合先：B の出どころが 2 つ以上
- 出現：B の出どころがない

主結果は $\theta = 0.3$ とし，感度分析として $\theta = 0.2,\ 0.4$ でも分類した．

5.5　安定性の検証

乱数シードを 20 通りに変え，次の 3 つを調べた．

1. **同じ窓の中の揺らぎ**：同じグラフを異なるシードで分割したときの NMI（シード 42 との比較）．

2. **隣接窓の NMI**：両方の窓を同じシードで分割したときの NMI.
3. **見かけの変化**：同じ窓をシード 42 と別のシードで分割した結果に，上の分類ルールを当てはめたときの分裂・統合の件数．グラフは同じなので，これはアルゴリズムの揺らぎだけで生じる変化である．

さらに，シード 42 で分裂と判定された各コミュニティについて，他のシードの分割で最も対応する（Jaccard 係数が最大の）コミュニティも分裂と判定される割合を**再現率**とした．

5.6 特徴の比較

分類した前の窓のコミュニティについて，人数，内部密度，内部辺の割合（内部の辺 ÷（内部の辺 + 外へ出る辺）），平均次数を分類ごとに比べた．事例数が少なく，同じ窓のコミュニティ同士は独立とは限らないため，統計的検定は行わず，件数と中央値による記述にとどめた．

6 結果

6.1 窓 0〜4 の概要と隣接窓の NMI

窓 0〜4 のコミュニティ数は 9〜12，Modularity は 0.486〜0.513 であった（表 1，図 1）．隣接窓の NMI は 0.613〜0.711 であり，AMI は NMI より約 0.01 低いだけであった（表 3）．

表 3　隣接窓の比較（共通ノードのみ，シード 42）

比較	共通	抜けた人	加わった人	NMI	AMI
0 → 1	730	59	49	0.679	0.668
1 → 2	724	55	59	0.711	0.700
2 → 3	735	48	70	0.650	0.640
3 → 4	756	49	94	0.613	0.603

6.2 変化の分類

$\theta = 0.3$ では，前の窓の 43 個のコミュニティのうち，21 個が維持，9 個が分裂，13 個が統合に分類され，消滅はなかった（表 4，図 2）．分裂の件数は θ に強く依存し，$\theta = 0.2$ では 13 件，0.4 では 2 件であった．一方，統合の件数は θ によらず 13〜14 件でほぼ一定であった（表 5）．

6.3 安定性

同じ窓を異なるシードで分割したときの NMI は，平均 0.759〜0.850（範囲 0.701〜0.916）であった．これに対し，隣接窓の NMI は平均 0.659〜0.685（範囲 0.610〜0.729）であり，どの窓の中の揺らぎの平均よりも低かった（図 3）．両者の分布は，端でわずかに重なるだけであった．

一方，個々の分裂・統合については結果が異なった．同じ窓をシードだけ変えて比べても，平均 0.25〜2.15 件の分裂と 0.60〜2.60 件の統合が判定された（表 6）．これは，実際の隣接窓で判定される件数（20 シード平均で分裂 0.95〜1.95 件，統合 1.70〜3.55 件）と同程度である．また，シード 42 で分裂と判定された 9 件の

表 4　変化の分類（$\theta = 0.3$，シード 42）

比較	コミュニティ数	維持	分裂	統合	消滅	統合先	出現
$0 \to 1$	11	7	0	4	0	2	0
$1 \to 2$	11	6	4	1	0	2	0
$2 \to 3$	12	4	2	6	0	3	0
$3 \to 4$	9	4	3	2	0	0	1
合計	43	21	9	13	0	7	1

表 5　閾値 θ を変えたときの件数（4 組の合計）

θ	維持	分裂	統合	消滅	統合先	出現
0.2	17	13	13	0	11	1
0.3	21	9	13	0	7	1
0.4	25	2	14	2	2	3

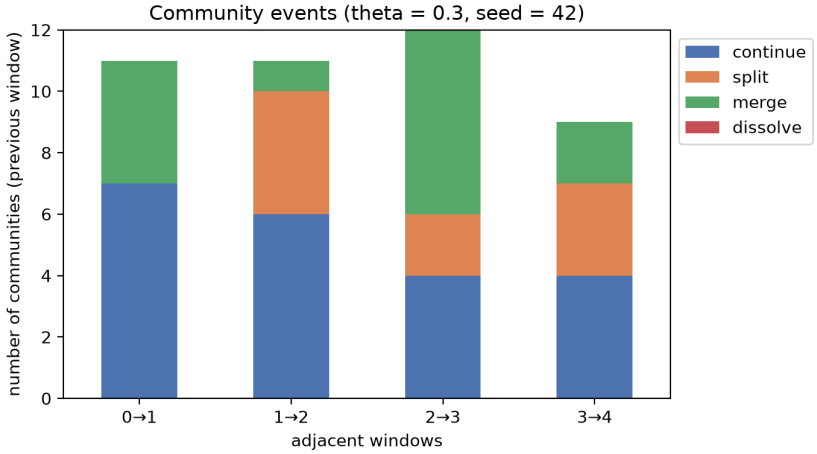


図 2　隣接窓ごとの変化の件数（$\theta = 0.3$，シード 42）

再現率は 0.05〜0.50 であり，20 シードの半数を超えて再現された分裂はなかった．

6.4　変化とコミュニティの特徴

表 7 と図 4 に，分類ごとのコミュニティの特徴を示す．分裂したコミュニティは維持されたコミュニティより内部辺の割合が低く（中央値 0.383 と 0.526），統合したコミュニティは人数が少なく内部密度が高い傾向があった．ただし，前節のとおり分類そのものがシードによって変わりやすいため，これはシード 42 の 1 回の実行に基づく記述である．

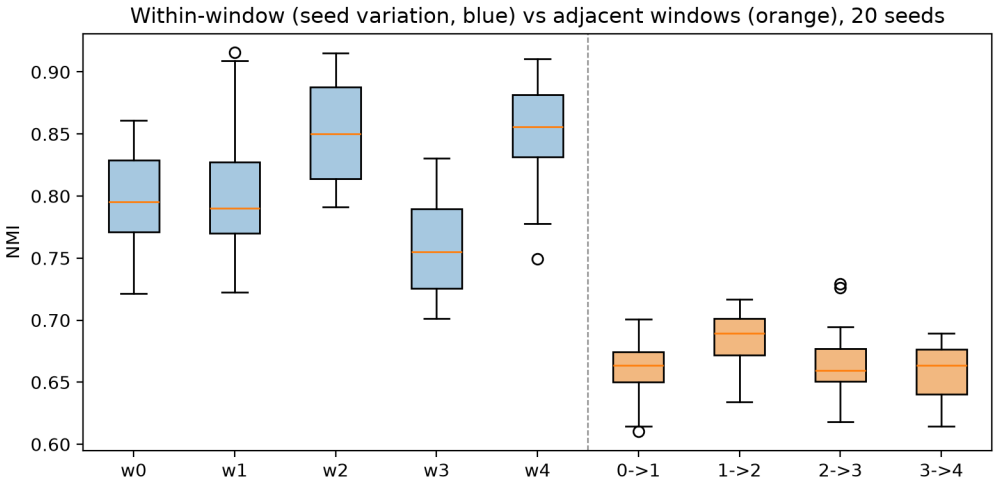


図 3　同じ窓の中の揺らぎ（青）と隣接窓（橙）の NMI（20 シード）

表 6　実際の変化と見かけの変化（20 シード平均）

	分裂		統合	
比較の前の窓	実際	見かけ	実際	見かけ
窓 0（0 → 1）	0.95	0.25	3.55	2.60
窓 1（1 → 2）	1.95	1.55	2.25	2.45
窓 2（2 → 3）	1.15	0.60	3.50	2.40
窓 3（3 → 4）	1.40	2.15	1.70	0.60

表 7　分類ごとのコミュニティの特徴（中央値，$\theta = 0.3$，シード 42）

分類	件数	人数（範囲）	内部密度	内部辺の割合	平均次数
維持	21	92（15–186）	0.124	0.526	17.8
分裂	9	55（20–146）	0.130	0.383	14.5
統合	13	31（6–75）	0.286	0.465	13.1

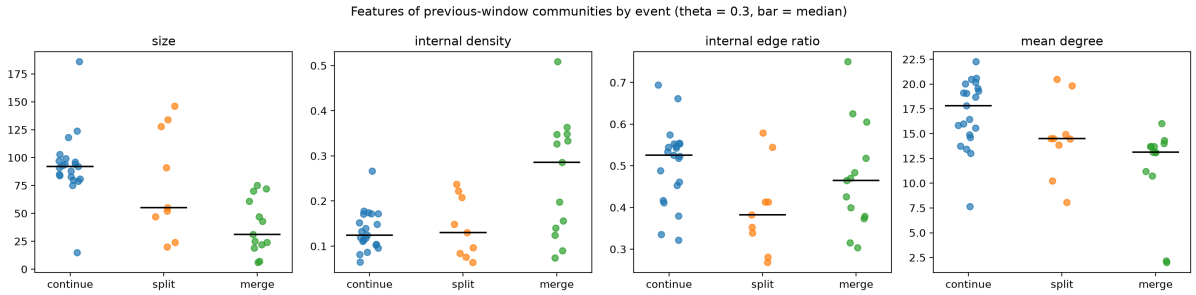


図 4　分類ごとのコミュニティの特徴（点は各コミュニティ，横線は中央値）

6.5 補足分析

■重み付きグラフ メール数を重みとすると，同じ窓の中の揺らぎは小さくなった（NMI 平均 0.845〜0.939）．隣接窓の NMI（0.593〜0.663）は，重みなしと同様に窓の中の揺らぎより低かった．一方，分類の件数は維持 35 件，分裂 6 件，統合 17 件（前の窓のコミュニティ 58 個）となり，どの組で分裂・統合が多いかは重みなしと一致しなかった．

■窓 5 と窓 7 ＋ 8 窓 4（100 日）→窓 5（26 日）の NMI は 0.710 であり，同じ「100 日→次の窓の最初の 26 日」の比較（窓 0〜3，0.585〜0.721）の範囲に収まった．窓 5 →窓 7 ＋ 8 は 271 日の空白をはさむが，NMI は 0.561（AMI 0.536）で，ラベルをランダムに並べ替えた場合（0.056）を大きく上回った．

7 考察

窓全体の分割の水準では，隣接窓の差は Louvain 法の実行ごとの揺らぎより大きかった．したがって，時間とともにコミュニティ構造が変化していることは，アルゴリズムの揺らぎだけでは説明しにくい．

一方，個々のコミュニティの水準では，判定される分裂・統合の件数が揺らぎだけで生じる件数と同程度であり，個々の分裂の再現率も低かった．したがって，今回の方法で検出された個々の分裂・統合を，安定した変化として扱うことはできない．中間発表で見られた分裂の兆候も，アルゴリズムの揺らぎで説明できる範囲にあり，実際の変化であるとは確認できなかった．まとめると，構造全体は変化しているが，どのコミュニティが分裂・統合したかを Louvain 法の 1 回の実行から特定することは難しい．

重み付きグラフを用いた補足分析でも，隣接窓の差は揺らぎより大きいという結論は変わらなかった．一方で，個々の分裂・統合の件数や，それが多く生じる時期は重みの有無によって変わったため，これらはグラフの作り方に依存すると考えられる．

また，記録が途切れる直前の窓 5 でも，コミュニティ構造の変化は通常の時期と同程度であり，特別な変化は見られなかった．長い空白の後でも，共通する人たちの所属関係には偶然以上の対応が残っていた．ただし，空白をはさむ比較には同じ条件の基準がなく，窓 5 の人の約 3 割は空白の後に現れないため，空白の前後で構造がどの程度変わったかまでは評価できない．

8 限界

1. **検出の揺らぎ**：Louvain 法は乱数シードによって分割が変わり，個々の分裂・統合の判定は安定しなかった．
2. **グラフの作り方**：主分析は無向・重みなしであり，送受信の向きとメールの量を使っていない．重みを付けると個々の判定が変わった．
3. **共通ノードのみの比較**：参加・離脱した人（各窓の 6〜11%）は変化の分類に含まれていない．
4. **閾値への依存**：分裂の件数は θ に強く依存した．
5. **時間窓の区切り方**：100 日固定で区切っており，区切り方を変えた場合は検証していない．また，窓 5 以降は観測期間が短いため主分析から外した．
6. **事例数**：分裂は 9 件と少なく，特徴の比較は記述にとどまる．分裂の予測可能性を検討できるだけの事例数はない．

7. **解釈の範囲**：分裂・統合はネットワーク上の検出結果の変化であり，実際の組織の変化を示すものではない．中間発表で予定していた部署情報との照合は，今回は行っていない．

9　今後の展望

前章で述べたとおり，今回の研究にはいくつかの限界がある．まず，個々の分裂・統合の判定を安定させるため，複数の seed 値で得た分割を統合して 1 つの分割を作る方法（コンセンサスクラスタリング）を試したい．また，今回は無向グラフを扱ったが，メールの送受信は有向グラフとしても表せるため，向きを考慮した分析も行いたい．時間窓の区切り方も早い段階で決めてしまったため，時間幅や区切り方を変えた場合に結果がどう変わるかも検証したい．さらに，中間発表で予定していた，検出したコミュニティと実際の部署情報との照合も行いたい．

本データでは分裂の事例数が少なく，予測を検討するには規模が足りなかった．今後は，より大規模なデータに対して同様の時間窓分析を行い，一部の期間で得た結果をもとに残りの期間の変化を予測し，その精度を調べることにも取り組みたい．

10　おわりに

展望でも述べたが，今後はより大規模なデータで分裂・統合などの判定を安定させるとともに，予測につなげるところまで取り組みたいと考えている．

11　再現方法

分析は Python 3.12.3，NetworkX 3.6.1，pandas 3.0.5，scikit-learn 1.9.1 で行った．コミュニティ検出の乱数シードは，主結果で 42，安定性の検証で 0〜19 である．計算はリポジトリ内の `notebooks/03_main_analysis.ipynb` で再現でき，実行時間は約 30 秒である．データの前処理と各時間窓の基礎的な分析は `notebooks/02_email_eu_core_analysis_organized.ipynb` にまとめた．

参考文献

[1] M. E. J. Newman and M. Girvan, “Finding and evaluating community structure in networks,” *Physical Review E*, vol. 69, 026113, 2004.

[2] M. E. J. Newman, “Modularity and community structure in networks,” *Proceedings of the National Academy of Sciences*, vol. 103, no. 23, pp. 8577–8582, 2006.

[3] V. D. Blondel, J.-L. Guillaume, R. Lambiotte, and E. Lefebvre, “Fast unfolding of communities in large networks,” *Journal of Statistical Mechanics: Theory and Experiment*, vol. 2008, no. 10, P10008, 2008.

[4] NetworkX Developers, “louvain_communities,” NetworkX 3.6.1 Documentation.

[5] P. Jaccard, “Étude comparative de la distribution florale dans une portion des Alpes et des Jura,” *Bulletin de la Société Vaudoise des Sciences Naturelles*, vol. 37, pp. 547–579, 1901.

[6] T. M. Cover and J. A. Thomas, *Elements of Information Theory*, 2nd ed., John Wiley & Sons, 2006,

ch. 2.

[7] A. Strehl and J. Ghosh, "Cluster ensembles—a knowledge reuse framework for combining multiple partitions," *Journal of Machine Learning Research*, vol. 3, pp. 583–617, 2002.

[8] N. X. Vinh, J. Epps, and J. Bailey, "Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance," *Journal of Machine Learning Research*, vol. 11, pp. 2837–2854, 2010.

[9] L. Hubert and P. Arabie, "Comparing partitions," *Journal of Classification*, vol. 2, pp. 193–218, 1985.

[10] K. Siegrist, "The hypergeometric distribution," in *Probability, Mathematical Statistics, and Stochastic Processes*, Section 12.2, LibreTexts Statistics.

[11] B. Illowsky and S. Dean, *Introductory Statistics 2e*, Section 4.5 "Hypergeometric Distribution," OpenStax.

[12] scikit-learn Developers, "adjusted_mutual_info_score," scikit-learn 1.9.1 Documentation.

[13] scikit-learn Developers, "normalized_mutual_info_score," scikit-learn 1.9.1 Documentation.